

*Krótkie wprowadzenie do spektralnej analizy
skupień
Duże zbiory danych*

Sławomir T. Wierzchoń

http://www.ipipan.waw.pl/~stw/sem190218/ML_PG.pdf

Instytut Podstaw Informatyki PAN



Seminarium „Machine Learning Gdańsk”
Gdańsk, 19 lutego 2018



Treść

- 1 Szybkie intro
- 2 Algorytm NJW
- 3 Wady „klasycznego” grupowania spektralnego
- 4 Szybkie grupowanie spektralne
 - Sygnały i ich filtrowanie
 - Szacowanie odległości w przestrzeni spektralnej
 - Przybliżone wyznaczanie λ_k
 - Compressive spectral clustering



Literatura

- strona: [Applications of spectral graph theory](#)
- U. von Luxburg. [A tutorial on spectral clustering](#). *Statistics and Computing*, 17(4):395-416, 2007
- H. Jia, et al. [The latest research progress on spectral clustering](#). *Neural Comput. & Applic.*, 24(7-8):1477-1486, 2014
- M. Filippone, et al. [A survey on spectral and kernel methods for clustering](#). *Pattern Recognition*, 41(1):176-190, 2008
- F. Chung. *Spectral Graph Theory*. AMS, Providence, RI, 1997
- S.T. Wierzchoń, M.A. Kłopotek. [Modern Algorithms of Cluster Analysis](#), Springer 2018





Szybkie intro

- $X = (\mathbf{x}_1, \dots, \mathbf{x}_m)^T \in \mathbb{R}^{m \times n}$ – macierz danych.
- $S \in \mathbb{R}^{m \times m}$ – macierz podobieństwa; $s_{ij} = \mathfrak{s}(\mathbf{x}_i, \mathbf{x}_j)$, np.
 $s_{ij} = \exp(\|\mathbf{x}_i - \mathbf{x}_j\|^2 / \sigma^2)$, przy czym $s_{ij} = 0$ gdy
 $\exp(\|\mathbf{x}_i - \mathbf{x}_j\|^2 / \sigma^2) \leq \tau$.
- Podsumowaniem jest nieskierowany, ważony graf
 $\Gamma = (V, E, S)$, gdzie $V = \{v_1, \dots, v_m\} = \{1, \dots, m\}$,
 $\{i, j\} \in E$ gdy $s_{ij} > 0$.



Skupienie – różne spojrzenia



Rysunek: Spojrzenie „globalne”: skupienia to zwarte i dobrze separowalne grupy obiektów vs spojrzenie „lokalne”: skupienie to zbiór wzajemnie podobnych obiektów.



Szybkie intro: kryteria rozcinania grafu

Niech $\text{cut}(A, B) = \sum_{i \in A} \sum_{j \in B} s_{ij}$. Wówczas

$$\text{cut}(C_1, \dots, C_k) = \sum_{j=1}^k \text{cut}(C_j, C_j^c)$$

$$\text{RCut}(C_1, \dots, C_k) = \sum_{j=1}^k \frac{\text{cut}(C_j, C_j^c)}{|C_j|}$$

$$\text{NCut}(C_1, \dots, C_k) = \sum_{j=1}^k \frac{\text{cut}(C_j, C_j^c)}{\text{vol}(C_j)}$$

$$\text{gdzie } C_j^c = V \setminus C_j, \quad \text{vol}(C_j) = \sum_{i \in C_j} d_i$$



Szybkie intro: Laplasjan kombinatoryczny


- $L = D - S$, gdzie $D = \text{diag}(S\mathbf{e}) = \text{diag}(d_1, \dots, d_m)$.
- L symetryczna i dodatnio pół-określona, tzn.

$$\mathbf{x}^T L \mathbf{x} = \frac{1}{2} \sum_{i,j=1}^m s_{ij} (x_i - x_j)^2$$
- $L = U \Lambda U^T$, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$, $U = (\mathbf{u}_1, \dots, \mathbf{u}_m)$, oraz
 $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m$. $\mathbf{u}_1 = c\mathbf{e} \Rightarrow \sum_j u_{j2} = 0$.
- $(\Gamma \text{ spójny}) \Rightarrow \lambda_2 > 0$. Jeżeli $\Gamma' = (V, E')$, $E' \subset E$ to
 $\lambda_2(\Gamma') \leq \lambda_2(\Gamma)$


Przykład: Graf i jego laplasjan

$$S = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}, \mathbf{d} = \begin{bmatrix} 2 \\ 3 \\ 2 \\ 1 \end{bmatrix}$$

$$L = D - S = \begin{bmatrix} 2 & -1 & -1 & 0 \\ -1 & 3 & -1 & -1 \\ -1 & -1 & 2 & 0 \\ 0 & -1 & 0 & 1 \end{bmatrix}$$



Przykład: Porządek Fiedlera




(a)

(b)


Rysunek: macierz L : (a) oryginalna, (b) po posortowaniu względem wartości u_2



Przykład: Porządek Fiedlera



(a)



(b)

Rysunek: macierz L : (a) oryginalna, (b) po posortowaniu względem wartości u_2



Szybkie intro: normalizowany Laplasjan

- $\mathcal{L} = D^{-1/2} L D^{-1/2} = \mathbb{I} - D^{-1/2} S D^{-1/2}$.
- \mathcal{L} symetryczna i dodatnio pół-określona, tzn.
 $\mathbf{x}^T \mathcal{L} \mathbf{x} = \frac{1}{2} \sum_{i,j=1}^m s_{ij} (x_i / \sqrt{d_i} - x_j / \sqrt{d_j})^2$
- $\mathcal{L} = U \Lambda U^T$, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$, $U = (\mathbf{u}_1, \dots, \mathbf{u}_m)$, oraz
 $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m \leq 2$. $\mathbf{u}_1 = D^{1/2} \mathbf{e}$. $\lambda_m = 2$ w.t.w. Γ –
 graf dwudzielny.



Szybkie intro: więcej o $RCut$ (1)

Niech $H = (\mathbf{h}_1, \dots, \mathbf{h}_k)$ będzie macierzą taką, że

$$h_{ij} = \begin{cases} 1/\sqrt{|C_j|} & v_i \in C_j \\ 0 & \text{wp.p.} \end{cases}, \quad i = 1, \dots, m, j = 1, \dots, k$$

Mamy $\|\mathbf{h}_j\| = \mathbf{h}_j^T \mathbf{h}_j = 1$, $\mathbf{h}_i^T \mathbf{h}_j = 0$, $i \neq j$ tzn. $H^T H = \mathbb{I}$.

$$\mathbf{h}_j^T L \mathbf{h}_j = \sum_{\alpha, \beta} s_{\alpha, \beta} (h_{\alpha j} - h_{\beta j})^2 = \frac{\text{cut}(C_j, C_j^c)}{|C_j|} = (H^T L H)_{jj}$$

$$RCut(C_1, \dots, C_k) = \sum_{j=1}^k \mathbf{h}_j^T L \mathbf{h}_j = \sum_{j=1}^k (H^T L H)_{jj} = \text{tr}(H^T L H)$$



Szybkie intro: więcej o $RCut$ (2)

$$\min_{(C_1, \dots, C_k) \in \mathcal{C}^k} \text{tr}(H^T L H), \text{ gdzie } H \text{ jak wyżej}$$

Relaksacja:

$$\min_{\substack{H \in \mathbb{R}^{n \times k} \\ H^T H = \mathbb{I}}} \text{tr}(H^T L H)$$

Na mocy tw. Fan'a (1947), por. ([Mirzal & Furukawa, 2010](#))

$$\min_{\substack{H \in \mathbb{R}^{n \times k} \\ H^T H = \mathbb{I}}} \text{tr}(H^T L H) = \sum_{j=1}^k \lambda_j \quad \text{jeżeli } H = (\mathbf{u}_1, \dots, \mathbf{u}_k) R$$

gdzie \mathbf{u}_i - wektor własny odpowiadający i -tej minimalnej w.w. λ_i laplasjanu L , oraz $R \in \mathbb{C}^{k \times k}$ – macierz unitarna.



Szybkie intro: więcej o $NCut$ (1)

Niech $H = (\mathbf{h}_1, \dots, \mathbf{h}_k)$ będzie macierzą taką, że

$$h_{ij} = \begin{cases} 1/\sqrt{\text{vol}(C_j)} & v_i \in C_j \\ 0 & \text{wp.p.} \end{cases}, \quad i = 1, \dots, m, j = 1, \dots, k$$

Mamy $\mathbf{h}_j^T D \mathbf{h}_j = 1$, $\mathbf{h}_i^T \mathbf{h}_j = 0$, $i \neq j$ tzn. $H^T D H = \mathbb{I}$.

$$\mathbf{h}_j^T L \mathbf{h}_j = \sum_{\alpha, \beta} s_{\alpha, \beta} (h_{\alpha j} - h_{\beta j})^2 = \frac{\text{cut}(C_j, C_j^c)}{\text{vol}(C_j)} = (H^T L H)_{jj}$$

$$NCut(C_1, \dots, C_k) = \sum_{j=1}^k \mathbf{h}_j^T L \mathbf{h}_j = \sum_{j=1}^k (H^T L H)_{jj} = \text{tr}(H^T L H)$$



Szybkie intro: więcej o $Ncut$ (2)

Relaksacja zadania NCut przyjmuje postać

$$\min_{\substack{H \in \mathbb{R}^{n \times k} \\ H^T D H = \mathbb{I}}} \text{tr}(H^T L H)$$

Niech $Q = D^{1/2} H$. Wówczas

$$\min_{\substack{Q \in \mathbb{R}^{n \times k} \\ Q^T Q = \mathbb{I}}} \text{tr}[Q^T (D^{-1/2} L D^{-1/2}) Q] = \min_{\substack{Q \in \mathbb{R}^{n \times k} \\ Q^T Q = \mathbb{I}}} \text{tr}(Q^T \mathcal{L} Q)$$

i można skorzystać z tw. Fan'a (1949), tzn. rozwiązaniem jest $Q = (\mathbf{u}_1, \dots, \mathbf{u}_k) R$, gdzie \mathbf{u}_i to i -ty wektor własny macierzy $\mathcal{L} = D^{-1/2} L D^{-1/2}$.



Algorytm NJW (Ng, Jordan & Weiss, 2002) – skąd taki pomysł?

Dane są 3 **rozłączne** grupy C_1, C_2, C_3

$$S = \begin{bmatrix} S^{(1)} & 0 & 0 \\ 0 & S^{(2)} & 0 \\ 0 & 0 & S^{(3)} \end{bmatrix} \Rightarrow \mathcal{L} = \begin{bmatrix} \mathcal{L}^{(1)} & 0 & 0 \\ 0 & \mathcal{L}^{(2)} & 0 \\ 0 & 0 & \mathcal{L}^{(3)} \end{bmatrix}$$

Dominujące wektory własne

$$Y = \begin{bmatrix} y^{(1)} & 0 & 0 \\ 0 & y^{(2)} & 0 \\ 0 & 0 & y^{(3)} \end{bmatrix}, y^{(i)} = \sqrt{D^{(i)}} \mathbf{e}_{C_i} \Rightarrow Z = \begin{bmatrix} \mathbf{e}_{C_1} & 0 & 0 \\ 0 & \mathbf{e}_{C_2} & 0 \\ 0 & 0 & \mathbf{e}_{C_3} \end{bmatrix}$$



Algorytm NJW (Ng, Jordan & Weiss, 2002) – skąd taki pomysł?

Dane są 3 **rozłączne** grupy C_1, C_2, C_3

$$S = \begin{bmatrix} S^{(1)} & 0 & 0 \\ 0 & S^{(2)} & 0 \\ 0 & 0 & S^{(3)} \end{bmatrix} \Rightarrow \mathcal{L} = \begin{bmatrix} \mathcal{L}^{(1)} & 0 & 0 \\ 0 & \mathcal{L}^{(2)} & 0 \\ 0 & 0 & \mathcal{L}^{(3)} \end{bmatrix}$$

Dominujące wektory własne

$$Y = \begin{bmatrix} y^{(1)} & 0 & 0 \\ 0 & y^{(2)} & 0 \\ 0 & 0 & y^{(3)} \end{bmatrix}, y^{(i)} = \sqrt{D^{(i)}} \mathbf{e}_{C_i} \Rightarrow Z = \begin{bmatrix} \mathbf{e}_{C_1} & 0 & 0 \\ 0 & \mathbf{e}_{C_2} & 0 \\ 0 & 0 & \mathbf{e}_{C_3} \end{bmatrix}$$



Algorytm NJW (Ng, Jordan & Weiss, 2002) – skąd taki pomysł?

Dane są 3 **rozłączne** grupy C_1, C_2, C_3

$$S = \begin{bmatrix} S^{(1)} & 0 & 0 \\ 0 & S^{(2)} & 0 \\ 0 & 0 & S^{(3)} \end{bmatrix} \Rightarrow \mathcal{L} = \begin{bmatrix} \mathcal{L}^{(1)} & 0 & 0 \\ 0 & \mathcal{L}^{(2)} & 0 \\ 0 & 0 & \mathcal{L}^{(3)} \end{bmatrix}$$

Dominujące wektory własne

$$Y = \begin{bmatrix} y^{(1)} & 0 & 0 \\ 0 & y^{(2)} & 0 \\ 0 & 0 & y^{(3)} \end{bmatrix}, y^{(i)} = \sqrt{D^{(i)}} \mathbf{e}_{C_i} \Rightarrow Z = \begin{bmatrix} \mathbf{e}_{C_1} & 0 & 0 \\ 0 & \mathbf{e}_{C_2} & 0 \\ 0 & 0 & \mathbf{e}_{C_3} \end{bmatrix}$$



Algorytm NJW (Ng, Jordan & Weiss, 2002) – skąd taki pomysł?

Dane są 3 **rozłączne** grupy C_1, C_2, C_3

$$S = \begin{bmatrix} S^{(1)} & 0 & 0 \\ 0 & S^{(2)} & 0 \\ 0 & 0 & S^{(3)} \end{bmatrix} \Rightarrow \mathcal{L} = \begin{bmatrix} \mathcal{L}^{(1)} & 0 & 0 \\ 0 & \mathcal{L}^{(2)} & 0 \\ 0 & 0 & \mathcal{L}^{(3)} \end{bmatrix}$$

Dominujące wektory własne

$$Y = \begin{bmatrix} y^{(1)} & 0 & 0 \\ 0 & y^{(2)} & 0 \\ 0 & 0 & y^{(3)} \end{bmatrix}, y^{(i)} = \sqrt{D^{(i)}} \mathbf{e}_{C_i} \Rightarrow Z = \begin{bmatrix} \mathbf{e}_{C_1} & 0 & 0 \\ 0 & \mathbf{e}_{C_2} & 0 \\ 0 & 0 & \mathbf{e}_{C_3} \end{bmatrix}$$



Algorytm NJW

WE: symetryczna macierz S taka, że $s_{ii} = 0$

- 1 wyznacz $\mathcal{S} = D^{-1/2} S D^{-1/2}$,
 $D = \text{diag}(S\mathbf{e}) = \text{diag}(d_1, \dots, d_m)$
- 2 wyznacz $Y = (\mathbf{y}_1, \dots, \mathbf{y}_k)$; \mathbf{y}_j – j -ty dominujący wektor własny \mathcal{S}
- 3 rzutuj wiersze macierzy Y na sferę jednostkową, tzn. utwórz macierz $Z = [z_{ij}]$, $i = 1, \dots, m$, $j = 1, \dots, k$ o elementach

$$z_{ij} = y_{i,j} / \|\mathbf{y}_i\|$$

- 4 wyznacz finalny podział danych reprezentowanych przez macierz Z .



Algorytm NJW

WE: symetryczna macierz S taka, że $s_{ii} = 0$

- 1 wyznacz $\mathcal{S} = D^{-1/2}SD^{-1/2}$,
 $D = \text{diag}(\mathbf{S}\mathbf{e}) = \text{diag}(d_1, \dots, d_m)$
- 2 wyznacz $Y = (\mathbf{y}_1, \dots, \mathbf{y}_k)$; \mathbf{y}_j – j -ty dominujący wektor własny \mathcal{S}
- 3 rzutuj wiersze macierzy Y na sferę jednostkową, tzn. utwórz macierz $Z = [z_{ij}]$, $i = 1, \dots, m$, $j = 1, \dots, k$ o elementach

$$z_{ij} = y_{i,j} / \|\mathbf{y}_{i\cdot}\|$$

- 4 wyznacz finalny podział danych reprezentowanych przez macierz Z .



Algorytm NJW

WE: symetryczna macierz S taka, że $s_{ii} = 0$

- 1 wyznacz $\mathcal{S} = D^{-1/2}SD^{-1/2}$,
 $D = \text{diag}(\mathbf{S}\mathbf{e}) = \text{diag}(d_1, \dots, d_m)$
- 2 wyznacz $Y = (\mathbf{y}_1, \dots, \mathbf{y}_k)$; \mathbf{y}_j – j -ty dominujący wektor własny \mathcal{S}
- 3 rzutuj wiersze macierzy Y na sferę jednostkową, tzn. utwórz macierz $Z = [z_{ij}]$, $i = 1, \dots, m$, $j = 1, \dots, k$ o elementach

$$z_{ij} = y_{i,j} / \|\mathbf{y}_j\|$$

- 4 wyznacz finalny podział danych reprezentowanych przez macierz Z .



Algorytm NJW

WE: symetryczna macierz S taka, że $s_{ii} = 0$

- 1 wyznacz $\mathcal{S} = D^{-1/2}SD^{-1/2}$,
 $D = \text{diag}(\mathbf{S}\mathbf{e}) = \text{diag}(d_1, \dots, d_m)$
- 2 wyznacz $Y = (\mathbf{y}_1, \dots, \mathbf{y}_k)$; \mathbf{y}_j – j -ty dominujący wektor własny \mathcal{S}
- 3 rzutuj wiersze macierzy Y na sferę jednostkową, tzn. utwórz macierz $Z = [z_{ij}]$, $i = 1, \dots, m$, $j = 1, \dots, k$ o elementach

$$z_{ij} = y_{i,j} / \|\mathbf{y}_{i\cdot}\|$$

- 4 wyznacz finalny podział danych reprezentowanych przez macierz Z .



Algorytm NJW

WE: symetryczna macierz S taka, że $s_{ii} = 0$

- 1 wyznacz $\mathcal{S} = D^{-1/2}SD^{-1/2}$,
 $D = \text{diag}(\mathbf{S}\mathbf{e}) = \text{diag}(d_1, \dots, d_m)$
- 2 wyznacz $Y = (\mathbf{y}_1, \dots, \mathbf{y}_k)$; \mathbf{y}_j – j -ty dominujący wektor własny \mathcal{S}
- 3 rzutuj wiersze macierzy Y na sferę jednostkową, tzn. utwórz macierz $Z = [z_{ij}]$, $i = 1, \dots, m$, $j = 1, \dots, k$ o elementach

$$z_{ij} = y_{i,j} / \|\mathbf{y}_{i\cdot}\|$$

- 4 wyznacz finalny podział danych reprezentowanych przez macierz Z .



Algorytm NJW - wyznaczanie finalnego podziału danych

Zastosuj:

- 1 algorytm k -średnich,
- 2 algorytm rotacji spektralnej (Huang, Nie, & Huang, 2013):
 $\min_{Q,H} \|YQ - H\|_F$ p.o. $Q^T Q = I, H \in \{0, 1\}^{m \times k}$,
- 3 QR faktoryzację (Zha, He, Ding, Gu, & Simon, 2001),
 (Freder, & van Barel, 2010), (Damle, Minden, & Ying)
 $[Q,R,P]=qr(Y^T)$; $\%Q^T Q = I, P$ – macierz permut.
 $u=inv(R(1:K,1:K))*R*P'$;
 $[tmp,r1]=max(abs(u^T),[],2)$;

Dla $Z \in \mathbb{R}^{2000 \times 3}$: wariant (1) trwa 0.03737 ± 0.00958 , a
 randomizowany wariant (3): $10^{-4}(4.8034 \pm 5.0504) \approx 0.001067$
 (średnie z 50 powtórzeń).



Algorytm NJW - wyznaczanie finalnego podziału danych

Zastosuj:

- 1 algorytm k -średnich,
- 2 algorytm rotacji spektralnej (Huang, Nie, & Huang, 2013):
 $\min_{Q,H} \|YQ - H\|_F$ p.o. $Q^T Q = \mathbb{I}$, $H \in \{0,1\}^{m \times k}$,
- 3 QR faktoryzację (Zha, He, Ding, Gu, & Simon, 2001),
 (Freder, & van Barel, 2010), (Damle, Minden, & Ying)
 $[Q,R,P]=qr(Y^T)$; $Q^T Q = \mathbb{I}$, P – macierz permut.
 $u = \text{inv}(R(1:K,1:K)) * R * P$;
 $[tmp,r1] = \max(\text{abs}(u^T), [], 2)$;

Dla $Z \in \mathbb{R}^{2000 \times 3}$: wariant (1) trwa 0.03737 ± 0.00958 , a
 randomizowany wariant (3): $10^{-4}(4.8034 \pm 5.0504) \approx 0.001067$
 (średnie z 50 powtórzeń).



Algorytm NJW - wyznaczanie finalnego podziału danych

Zastosuj:

- 1 algorytm k -średnich,
- 2 algorytm rotacji spektralnej (Huang, Nie, & Huang, 2013):
 $\min_{Q,H} \|YQ - H\|_F$ p.o. $Q^T Q = \mathbb{I}$, $H \in \{0, 1\}^{m \times k}$,
- 3 QR faktoryzację (Zha, He, Ding, Gu, & Simon, 2001),
 (Freder, & van Barel, 2010), (Damle, Minden, & Ying)
`[Q,R,P]=qr(YT); %QTQ = I, P – macierz permut.
 u=inv(R(1:K,1:K))*R*P';
 [tmp,r1]=max(abs(uT),[],2);`

Dla $Z \in \mathbb{R}^{2000 \times 3}$: wariant (1) trwa 0.03737 ± 0.00958 , a
 randomizowany wariant (3): $10^{-4}(4.8034 \pm 5.0504) \approx 0.001067$
 (średnie z 50 powtórzeń).



Algorytm NJW - wyznaczanie finalnego podziału danych

Zastosuj:

- 1 algorytm k -średnich,
- 2 algorytm rotacji spektralnej (Huang, Nie, & Huang, 2013):
 $\min_{Q,H} \|YQ - H\|_F$ p.o. $Q^T Q = \mathbb{I}$, $H \in \{0, 1\}^{m \times k}$,
- 3 QR faktoryzację (Zha, He, Ding, Gu, & Simon, 2001),
 (Freder, & van Barel, 2010), (Damle, Minden, & Ying)
 $[Q,R,P]=\text{qr}(Y^T)$; $\% Q^T Q = \mathbb{I}$, P – macierz permut.
 $u=\text{inv}(R(1:K,1:K))^*R^*P$;
 $[tmp,r1]=\text{max}(\text{abs}(u^T),[],2)$;

Dla $Z \in \mathbb{R}^{2000 \times 3}$: wariant (1) trwa 0.03737 ± 0.00958 , a
 randomizowany wariant (3): $10^{-4}(4.8034 \pm 5.0504) \approx 0.001067$
 (średnie z 50 powtórzeń).



Algorytm NJW - wyznaczanie finalnego podziału danych

Zastosuj:

- 1 algorytm k -średnich,
- 2 algorytm rotacji spektralnej (Huang, Nie, & Huang, 2013):
 $\min_{Q,H} \|YQ - H\|_F$ p.o. $Q^T Q = \mathbb{I}$, $H \in \{0, 1\}^{m \times k}$,
- 3 QR faktoryzację (Zha, He, Ding, Gu, & Simon, 2001),
 (Freder, & van Barel, 2010), (Damle, Minden, & Ying)
 $[Q,R,P]=\text{qr}(Y^T)$; $\% Q^T Q = \mathbb{I}$, P – macierz permut.
 $u=\text{inv}(R(1:K,1:K))^*R^*P$;
 $[tmp,r1]=\text{max}(\text{abs}(u^T),[],2)$;

Dla $Z \in \mathbb{R}^{2000 \times 3}$: wariant (1) trwa 0.03737 ± 0.00958 , a
 randomizowany wariant (3): $10^{-4}(4.8034 \pm 5.0504) \approx 0.001067$
 (średnie z 50 powtórzeń).



Algorytm NJW - wyznaczanie finalnego podziału danych

Zastosuj:

- 1 algorytm k -średnich,
- 2 algorytm rotacji spektralnej (Huang, Nie, & Huang, 2013):
 $\min_{Q,H} \|YQ - H\|_F$ p.o. $Q^T Q = \mathbb{I}$, $H \in \{0, 1\}^{m \times k}$,
- 3 QR faktoryzację (Zha, He, Ding, Gu, & Simon, 2001),
 (Freder, & van Barel, 2010), (Damle, Minden, & Ying)
 $[Q,R,P]=qr(Y^T)$; $Q^T Q = \mathbb{I}$, P – macierz permut.
 $u = \text{inv}(R(1:K, 1:K)) * R * P$;
 $[tmp, r1] = \max(\text{abs}(u^T), [], 2)$;

Dla $Z \in \mathbb{R}^{2000 \times 3}$: wariant (1) trwa 0.03737 ± 0.00958 , a
 randomizowany wariant (3): $10^{-4}(4.8034 \pm 5.0504) \approx 0.001067$
 (średnie z 50 powtórzeń).



Wyzwania podejścia spektralnego

- Złożoność pamięciowa: $O(m^2)$,
- Złożoność czasowa $O(m^3)$
- Konieczność reklasyfikacji
- Jak klasyfikować nowe obserwacje?



Wyzwania podejścia spektralnego

- Złożoność pamięciowa: $O(m^2)$,
- Złożoność czasowa $O(m^3)$
- Konieczność reklasyfikacji
- Jak klasyfikować nowe obserwacje?



Wyzwania podejścia spektralnego

- Złożoność pamięciowa: $O(m^2)$,
- Złożoność czasowa $O(m^3)$
- Konieczność reklasyfikacji
- Jak klasyfikować nowe obserwacje?



Wyzwania podejścia spektralnego

- Złożoność pamięciowa: $O(m^2)$,
- Złożoność czasowa $O(m^3)$
- Konieczność reklasyfikacji
- Jak klasyfikować nowe obserwacje?



Wyzwania podejścia spektralnego

- Złożoność pamięciowa: $O(m^2)$,
- Złożoność czasowa $O(m^3)$
- Konieczność reklasyfikacji
- Jak klasyfikować nowe obserwacje?



Nowe podejścia do pokonywania złożoności

- 1 **RanNLA** – Randomized Numerical Linear Algebra (Drineas, & Mahoney, 2016), (Mahoney, 2016): Randomizacja jako narzędzie wspomagające konstrukcję algorytmów o małym czasie wykonywania i lepszej stabilności. Jednym z głównych chwytów jest *sketching*: zastąpienie dużej macierzy A mniejszą, np. $\hat{A} = A\Omega$, która reprezentuje istotne własności A .
- 2 **Sparsity** (wybór podzbioru obserwacji z X): (Alzate, & Suykens, 2011), (Federix, & van Barel, 2010), oraz
- 3 **Compressed sensing**, np. (Tremblay, Puy, Gribonval, & Vandergheynst, 2016)



Nowe podejścia do pokonywania złożoności

- 1 **RanNLA** – Randomized Numerical Linear Algebra ([Drineas, & Mahoney, 2016](#)), ([Mahoney, 2016](#)): Randomizacja jako narzędzie wspomagające konstrukcję algorytmów o małym czasie wykonywania i lepszej stabilności. Jednym z głównych chwytów jest *sketching*: zastąpienie dużej macierzy A mniejszą, np. $\hat{A} = A\Omega$, która reprezentuje istotne własności A .
- 2 **Sparsity** (wybór podzbioru obserwacji z X): ([Alzate, & Suykens, 2011](#)), ([Federix, & van Barel, 2010](#)), oraz
- 3 **Compressed sensing**, np. ([Tremblay, Puy, Gribonval, & Vandergheynst, 2016](#))



Nowe podejścia do pokonywania złożoności

- 1 RanNLA** – Randomized Numerical Linear Algebra ([Drineas, & Mahoney, 2016](#)), ([Mahoney, 2016](#)): Randomizacja jako narzędzie wspomagające konstrukcję algorytmów o małym czasie wykonywania i lepszej stabilności. Jednym z głównych chwytów jest *sketching*: zastąpienie dużej macierzy A mniejszą, np. $\hat{A} = A\Omega$, która reprezentuje istotne własności A .
- 2 Sparsity** (wybór podzbioru obserwacji z X): ([Alzate, & Suykens, 2011](#)), ([Federix, & van Barel, 2010](#)), oraz
- 3 Compressed sensing**, np. ([Tremblay, Puy, Gribonval, & Vandergheynst, 2016](#))



Nowe podejścia do pokonywania złożoności

- 1 RanNLA** – Randomized Numerical Linear Algebra ([Drineas, & Mahoney, 2016](#)), ([Mahoney, 2016](#)): Randomizacja jako narzędzie wspomagające konstrukcję algorytmów o małym czasie wykonywania i lepszej stabilności. Jednym z głównych chwytów jest *sketching*: zastąpienie dużej macierzy A mniejszą, np. $\hat{A} = A\Omega$, która reprezentuje istotne własności A .
- 2 Sparsity** (wybór podzbioru obserwacji z X): ([Alzate, & Suykens, 2011](#)), ([Federix, & van Barel, 2010](#)), oraz
- 3 Compressed sensing**, np. ([Tremblay, Puy, Gribonval, & Vandergheynst, 2016](#))



Sygnały na grafach – literatura

- 1 A. Sandryhaila, J.M.F. Moura: [Big data analysis with signal processing on graphs](#)
- 2 D. Shuman *et al.* [The emerging field of signal processing on graphs](#)
- 3 D.K. Hammond *et al.* [Wavelets on graphs via spectral graph theory](#)
- 4 I. Pesenson: [Sampling in Paley-Wiener spaces on combinatorial graphs](#)





Sygnały i ich filtrowanie

- Sygnał: $\mathfrak{s}: V \rightarrow \mathbb{R}$; \mathfrak{s} zastępujemy przez wektor $\mathbf{s} \in \mathbb{R}^m$.
- Jeżeli $h: [0, 2] \rightarrow \mathbb{R}$, to $H = h(\mathcal{L}) = U h(\Lambda) U^T$ – filtr grafowy, przy czym $h(\Lambda) = \text{diag}(h(\lambda_1), \dots, h(\lambda_m))$. $H = H^T$.
 $\hat{\mathbf{s}} = H\mathbf{s} = (\mathbf{s}^T H)^T$ – przefiltrowany sygnał.
- Jeżeli $h_{\lambda_k}(\lambda) = 1$ gdy $\lambda \leq \lambda_k$ i $h_{\lambda_k}(\lambda) = 0$ w p.p., to $H_{\lambda_k} = U_k U_k^T$, gdzie $U_k = U(:, 1 : k)$ – filtr dolnoprzepustowy.
- Przyjmując wielomianową aproksymację $h(\xi) \approx \hat{h}(\xi) = \sum_{\ell=0}^p \alpha_\ell \xi^\ell$. W tym przypadku

$$H\mathbf{s} \approx \tilde{H}\mathbf{s} = \sum_{\ell=0}^p \alpha_\ell \mathcal{L}^\ell \mathbf{s}; \quad \mathcal{L}^\ell \mathbf{s} = \mathcal{L}(\mathcal{L}^{\ell-1} \mathbf{s})$$



Filtr dolnoprzepustowy – aproksymacja



Rysunek: Aproksymacja Czebyszewa (lewy rys.) oraz Czebyszewa-Jacksona (prawy). $\tilde{H}\mathbf{s} = \sum_{\ell=0}^p \alpha_{\ell} T_{\ell}(\mathcal{L})$, gdzie $T_0(\mathcal{L}) = \mathbf{s}$, $T_1(\mathcal{L}) = \mathcal{L}\mathbf{s} - \mathbf{s}$, $T_{\ell}(\mathcal{L}) = 2(\mathcal{L}T_{\ell-1}(\mathcal{L}) - T_{\ell-1}(\mathcal{L})) - T_{\ell-2}(\mathcal{L})$, $\ell > 1$.



Szacowanie odległości w przestrzeni spektralnej

Niech $H_{\lambda_k} = U_k U_k^T$, δ_i – i -ty wiersz macierzy \mathbb{I} . Niech $R^{m \times \eta}$ macierz o elementach $r_{ij} \sim \mathcal{N}(0, 1/\eta)$. Wtedy

$$(H_{\lambda_k} R)^T \delta_i = (R^T U_k)(U_k^T \delta_i) = R' \mathbf{f}_i$$

gdzie $\mathbf{f}_i = (\mathbf{y}^i)^T$ – transponowany i -ty wiersz macierzy $Y = U_k$ (krok 2 w NJW), a $R' = R^T U_k \in \mathbb{R}^{\eta \times m}$ macierz o elementach $r_{ij} \sim \mathcal{N}(0, 1/\eta)$.



Lemat Johnsona-Lindenstraussa (Achlioptas, 2003)

Lemma

Let P be an arbitrary set of m points in \mathbb{R}^n represented as an $m \times n$ matrix A . Given $\epsilon, \beta > 0$ let $\eta_0(m, \epsilon, \beta) = \frac{4+2\beta}{\epsilon^2/2-\epsilon^3/3} \ln m$. For any $\eta \geq \eta_0$ let R be a $n \times \eta$ random matrix with elements

$$r_{ij} \sim \mathcal{N}(0, 1/\eta), \quad r_{ij} = \begin{cases} +1 & p = 1/2 \\ -1 & p = 1/2 \end{cases}, \quad r_{ij} = \sqrt{\theta} \begin{cases} +1 & p = 1/(2\theta) \\ -1 & p = 1/(2\theta) \\ 0 & \text{otherwise} \end{cases}$$

Let $g: \mathbb{R}^n \rightarrow \mathbb{R}^\eta$ map i -th row of A to i -th row of $E = AR/\sqrt{\eta}$. Then with prob. at least $1 - m^{-\beta}$ for all $u, v \in P$

$$(1 - \epsilon) \|u - v\|^2 \leq \|g(u) - g(v)\|^2 \leq (1 + \epsilon) \|u - v\|^2$$





Zastosowanie lematu J-L

Przyjmując $g(\mathbf{f}_i) = R'\mathbf{f}_i = (H_{\lambda_k} R)^T \boldsymbol{\delta}_i = \tilde{\mathbf{f}}_i$ mamy

$$\tilde{d}_{ij} = \|\tilde{\mathbf{f}}_i - \tilde{\mathbf{f}}_j\| = \|g(\mathbf{f}_i) - g(\mathbf{f}_j)\|$$

Stosując lemat J-L stwierdzamy, że dla dowolnych $\epsilon \in (0, 1]$ i $\beta > 0$, jeżeli $\eta \geq \eta_0(m, \epsilon, \beta)$ to z prawdopodobieństwem przynajmniej $1 - m^{-\beta}$ mamy

$$(1 - \epsilon)d_{ij} \leq \tilde{d}_{ij} \leq (1 + \epsilon)d_{ij}$$

WAŻNE: H_{λ_k} można zastąpić jego aproksymacją \tilde{H}_{λ_k}



PROBLEM

JAK WYZNACZYĆ λ_k ?



Przybliżone wyznaczanie λ_k (1)

- E. Di Napoli *et al.*: [Efficient estimation of eigenvalue counts in an interval](#), T. Li *et al.*: [Fast compressive spectral clustering](#).
- Jeżeli A jest nieosobliwa i hermitowska, to $A = U\Lambda U^T$ przy czym liczba dodatnich wartości własnych (w.w.) A jest równa liczbie dodatnich w.w. Λ (*Sturm count*). Liczba $\mu_{[a,b]}$ w.w. należących do przedziału $[a, b]$ jest równa różnicy między liczbą dodatnich w.w. macierzy $A - b\mathbb{I}$ oraz $A - a\mathbb{I}$.
- Niech $P = \sum_{\lambda \in [a,b]} \mathbf{u}_\lambda \mathbf{u}_\lambda^T$ (*projektor spektralny*).

$$\mu_{[a,b]} = \text{tr}(P) = \frac{1}{n_v} \sum_{j=1}^{n_v} \mathbf{v}_j^T P \mathbf{v}_j,$$

$$\mu_{[a,b]} \approx \sum_{j=1}^{n_v} \sum_{i=0} \alpha_i \mathbf{v}_j^T T_i(\mathcal{L}) \mathbf{v}_j.$$




Przybliżone wyznaczanie λ_k (2)

- $\lambda_{min} = 0, \lambda_{max} = 2$
- **while** (counts =k)
 - $\lambda_{mid} = (\lambda_{min} + \lambda_{max})/2$
 - $jch = \text{jackson_cheby_poly_coeffs}(0, \lambda_{mid}, 0, 2, \text{order})$
 - **wyznacz** counts = $\mu_{[0, \lambda_{mid}]}$
 - **if** counts > k, $\lambda_{max} = \lambda_{mid}$, **else** $\lambda_{min} = \lambda_{mid}$;
- $\lambda_k = (\lambda_{min} + \lambda_{max})/2$

Przybliżone wyznaczenie λ_k

Przybliżone wyznaczenie λ_k (Przykład – sieć karate)



Rysunek: Rzeczywiste (niebieski) i przybliżone (czerwony) w.w.



Compressive spectral clustering (Tremblay et al., 2016)

- WE: laplasjan \mathcal{L} , liczba skupień k , parametry: $\eta = 4 \log m$, $p = 50$
- Wyznacz przybliżoną wartość $\tilde{\lambda}_k$
- Wyznacz aproksymacje $\tilde{h}_{\tilde{\lambda}_k}$ oraz $\tilde{H}_{\tilde{\lambda}_k}$
- Filtruj losową macierz R , $F = (\tilde{H}_{\tilde{\lambda}_k} R)$.
- Wyznacz wektory cech $\tilde{f}_i = (F^T \delta_i) / \|F^T \delta_i\|$
- zastosuj algorytm k -średnich do zbioru $\{\tilde{f}_1, \dots, \tilde{f}_m\}$.



Dziękuję za uwagę